

任务 1 实验报告

基于强化学习的倒立摆控制

课程：AI 赋能自动控制原理 日期：2025 年 7 月

1 问题分析

1.1 Cart Pole 系统与任务环境

Cart Pole（小车-倒立摆）是自动控制原理中经典的非线性系统控制案例。系统由一辆可在轨道上水平移动的小车和铰接于其上的摆杆组成。控制目标是施加水平力使摆杆始终保持直立。

本实验采用符合任务描述的自定义 CartPole 环境，基于 OpenAI Gymnasium 的物理引擎实现。环境参数：终止角度 15° （摆杆倾斜超过 15° 视为失去平衡），小车边界 2.4m，最大步数 500 步。奖励机制严格遵循任务描述：每步成功保持平衡获得 +1 正向奖励，失败（角度或位置超限）获得 -10 负向惩罚。

状态空间为 4 维连续向量（表 1），动作空间为离散二值（0 左移、1 右移）。

表 1: 状态空间

序号	符号	含义	单位
0	x	小车位置	m
1	$\dot{x}$	小车速度	m/s
2	θ	摆杆角度	rad
3	$\dot{\theta}$	摆杆角速度	rad/s

1.2 算法选择

本实验选用三种代表性算法进行对比研究：

PPO (Proximal Policy Optimization) 是当前主流的策略梯度算法，通过裁剪机制限制策略更新幅度，保证训练稳定性。超参数：学习率 3×10^{-4} ，n_steps 2,048，clip_range 0.2，GAE $\lambda = 0.95$ 。

A2C (Advantage Actor-Critic) 是同步优势演员-评论家算法，同时学习策略网络 (Actor) 和价值网络 (Critic)，利用优势函数降低策略梯度方差。超参数：学习率 7×10^{-4} ，n_steps 5，熵系数 0.01。

传统控制方法包括随机策略、规则控制器和 LQR 控制器，作为性能对比基线。

1.3 奖励函数设计

奖励函数严格遵循任务描述：

$$r_t = \begin{cases} +1, & \text{每步成功保持平衡} \\ -10, & \text{失败 } (|\theta| > 15^\circ \text{ 或 } |x| > 2.4\text{m}) \end{cases}$$

2 实验过程

2.1 环境构建与参数设置

使用自定义 CartPole 环境（自实现物理引擎）。PPO 训练 100,000 步，A2C 训练 100,000 步。随机种子 42，CPU 设备。

2.2 PPO 训练过程

PPO 在 100,000 步内完美求解任务环境（图 1）。训练过程可分为三个阶段：

- **探索期**（0–200 回合）：奖励在 10–40 之间波动，与随机策略相当，智能体尚未学到有效控制；
- **收敛期**（200–280 回合）：奖励快速攀升至 500，策略从随机探索转向有目的的平衡控制；
- **稳定求解期**（280 回合后）：持续稳定在满分 500，最后 100 回合均值 500.0，20 回合评估全部满分。




图 1： PPO 训练奖励曲线。灰色散点为每回合原始奖励，蓝色曲线为 10 窗口移动平均。虚线标注求解阈值（475）。红色虚线标注首次满分回合（Episode 280）。

2.3 A2C 训练过程

A2C 同样在 100,000 步内完成训练（图 2），但其学习模式与 PPO 有显著差异：

- **缓慢上升期**（0–1,000 回合）：均值在 10–40 之间波动，学习速度明显慢于 PPO；
- **波动攀升期**（1,000–1,500 回合）：出现多个奖励尖峰，最高达到满分 500（第 1,330 回合附近），但无法持续保持；
- **不稳定维持期**（1,500 回合后）：均值在 30–90 之间大幅波动，未能稳定收敛至满分。




图 2：A2C 训练奖励曲线。绿色散点为原始奖励，曲线为 50 窗口移动平均。A2C 在训练过程中多次达到高分但无法稳定保持，体现了演员-评论家方法在离散控制任务中的局限性。

2.4 传统控制对比

- **随机策略**：每步随机动作，平均仅 16.1 步。
- **LQR 控制器**：平衡点线性化后求解 Riccati 方程，平均 44.8 步。因 CartPole 强非线性，线性近似在大偏差时失效。
- **规则控制器**：基于角度阈值 ($|\theta| > 0.05 \text{ rad}$) 的简单反馈，平均 215.8 步，为传统方法中最优。

3 实验结果及分析

3.1 训练过程多指标分析

本节从奖励曲线、移动平均奖励、成功率和回合步数四个维度，对 PPO 和 A2C 的训练过程进行全面对比分析（图 3）。

Figure 6 | Multi-metric training analysis




图 3: 训练过程多指标对比面板。(a) 训练奖励曲线; (b) 100 回合移动平均奖励; (c) 100 回合滚动成功率 (阈值 475); (d) 回合步数变化。

奖励曲线分析 (图 6a): PPO (蓝色) 在约 280 回合处达到满分 500 后持续保持, 训练曲线呈平滑的 S 形增长。A2C (绿色) 的曲线呈现多个尖峰和回落, 说明 A2C 虽然偶有能力达到高分 (最高 500), 但策略稳定性不足。两种算法的收敛速度差异显著——PPO 的收敛速度约为 A2C 的 5 倍。

移动平均奖励 (图 6b): 100 回合滚动均值消除了短期波动, 更清晰地反映长期趋势。PPO 的滚动均值在 300 回合后稳定在 500 附近, 说明策略一旦收敛就不再退化。A2C 的滚动均值在 100-200 回合后稳定在 40-60 之间, 远低于 PPO 的 500, 且波动幅度大 (30-90), 反映 A2C 无法形成稳定的控制策略。

成功率分析 (图 6c): 以单回合奖励 ≥ 475 定义为成功, PPO 的成功率在 300 回合后稳定在 60%-100%, 累计成功 60/434 回合 (15.3%)。A2C 仅有少数回合达到 475 分以上, 累计成功率不足 1%。这一指标直观展示了 PPO 在任务求解能力上的绝对优势。

回合步数 (图 6d): 回合步数与奖励直接相关 (每步 +1)。PPO 在求解期的回合步数稳定在 500 (满分), A2C 的回合步数在 60-160 之间波动, 对应奖励在 50-150 之间。回合步数的波动反映了策略在不同初始条件下的鲁棒性差异。

表 2: 训练过程关键指标对比

指标	PPO	A2C
总训练步数	100,000	100,000
总回合数	434	1,788
首次求解回合	280	1,330
最高奖励	500	500
最后 100 回合均值	500.0	33.0
累计满分次数	60/434 (15.3%)	<10/1,788 (<0.6%)
评估均值 (20 回合)	500.0 ± 0.0	89.8 ± 7.4

3.2 控制方法综合对比

图 4 对比了五种控制方法的平均性能（20 回合评估）。




图 4: 五种控制方法平均奖励对比。PPO 满分 500，规则控制器 215.8 步，A2C 89.8 步，LQR 44.8 步，随机策略 16.1 步。

表 3: 控制方法性能对比（20 回合评估）

方法	平均奖励	标准差	最高奖励	达标率
随机策略	16.1	6.8	43	0%
LQR 控制器	44.8	7.4	52	0%
A2C	89.8	7.4	106	0%
规则控制器	215.8	29.1	293	0%
PPO	500.0	0.0	500	100%

3.3 训练前后控制效果

图 5 以箱线图和散点展示训练前后的奖励分布变化。




图 5: 训练前后 20 回合评估奖励分布。PPO（蓝色）完美压缩至满分 500，A2C（绿色）均值约 90，随机策略（灰色）均值约 16。散点为各回合个体数据。

3.4 PPO 与 A2C 的对比分析

PPO 全面优于 A2C 的原因可从算法设计角度解释：

(1) 裁剪机制 vs 无裁剪。PPO 的核心裁剪机制 ($\text{clip_range}=0.2$) 限制了策略的每步更新幅度，防止策略剧烈变化导致性能崩溃。A2C 作为标准演员-评论家算法，没有这种保护机制，容易出现“学得好、突然忘”的不稳定现象。

(2) 样本效率。PPO 每步收集 2,048 个样本后进行多轮更新 (10 epochs)，数据利用率高。A2C 每步仅收集 5 个样本 ($n_steps=5$)，更新频率高但每次更新信息量少，导致收敛速度慢。

(3) 探索策略。PPO 使用随机策略的固有随机性进行探索，随着策略收敛探索自然减小。A2C 的熵正则化 ($\text{ent_coef}=0.01$) 虽然鼓励探索，但效果有限。

4 总结体会

本实验严格按照任务描述实现了自定义 CartPole 环境 (15° 终止角、-10 失败惩罚)，对比了五种控制方法。

核心结论：

1. PPO 完美解决任务环境 (100% 达标率, 500 满分)，展示了策略梯度方法在离散控制任务中的卓越性能；

2. A2C 虽然能学到一定策略（评估均值 89.8），但稳定性不足，无法持续保持满分；
3. 规则控制器（215.8 分）在传统方法中表现最优，但远不及 PPO；
4. 多指标分析面板（奖励曲线、滚动均值、成功率、回合步数）提供了比单一指标更全面的训练过程评估。

改进方向：可尝试 SAC（Soft Actor-Critic）等更先进的算法；调整 A2C 的网络结构和超参数以提升稳定性；引入课程学习或模仿学习加速训练。

代码仓库：<https://github.com/zhaihuahua78/cartpole-->

报告完成日期：2025 年 7 月