

任务 1 实验报告

基于强化学习的倒立摆控制

课程：AI 赋能自动控制原理 日期：2025 年 7 月

1 问题分析

1.1 Cart Pole 系统与任务环境

Cart Pole（小车-倒立摆）是自动控制原理中经典的非线性系统控制案例。系统由一辆可在轨道上水平移动的小车和铰接于其上的摆杆组成，控制目标是通过施加水平力使摆杆始终保持直立。

本实验采用符合任务描述的自定义 CartPole 环境，参数如下：终止角度 15（摆杆倾斜超过 15 度视为失去平衡），小车边界 2.4m，最大步数 500 步。奖励机制严格遵循任务描述：每步成功保持平衡获得 +1 正向奖励，失败（角度或位置超限）获得-10 负向惩罚。

状态空间为 4 维连续向量（表 1），动作空间为离散二值（0 左移、1 右移）。

表 1: 状态空间

序号	符号	含义	单位
0	x	小车位置	m
1	$\dot{x}$	小车速度	m/s
2	θ	摆杆角度	rad
3	$\dot{\theta}$	摆杆角速度	rad/s

1.2 算法选择

本实验选用以下算法/方法进行对比研究：

PPO(Proximal Policy Optimization): 策略梯度算法, 通过裁剪机制 (clip_range=0.2) 限制策略更新幅度。超参数: 学习率 3×10^{-4} , n_steps 2,048, GAE $\lambda = 0.95$ 。

A2C (Advantage Actor-Critic): 同步优势演员-评论家算法。经超参数扫描 (7 种配置), 最优配置为 n_steps=64、学习率 5×10^{-4} 、熵系数 0.02。该配置下 A2C 后 100 回合均值达 464.5, 评估达标率 90%。

传统控制方法: 随机策略、规则控制器、LQR 控制器, 作为性能基线。

1.3 奖励函数设计

奖励函数严格遵循任务描述：

$$r_t = \begin{cases} +1, & \text{每步成功保持平衡} \\ -10, & \text{失败 } (|\theta| > 15^\circ \text{ 或 } |x| > 2.4 \text{ m}) \end{cases}$$

2 实验过程

2.1 环境构建与参数设置

使用自定义 CartPole 环境（自实现物理引擎）。PPO 和 A2C 各训练 200,000 步。随机种子 42，CPU 设备。

2.2 PPO 训练过程

PPO 在 200,000 步内完美求解（图 1），训练过程分为三个阶段：

- **探索期**（0–200 回合）：奖励 10–40，与随机策略相当，智能体尚未学到有效控制策略；
- **收敛期**（200–280 回合）：奖励从 40 快速攀升至 500，平滑进入求解状态；
- **稳定求解期**（280–737 回合）：持续稳定在满分 500，后 100 回合均值 500.0，无任何退化。

训练总回合 737，累计满分 161 次（21.8%）。20 回合确定性评估全部满分（500.0 ± 0.0），达标率 100%。




图 1： PPO 训练奖励曲线。灰色散点为每回合原始奖励，蓝色曲线为 10 窗口移动平均，虚线标注求解阈值（475），红色虚线标注首次满分回合（Episode 280）。

2.3 A2C 训练过程

A2C 经超参数优化后 ($n_steps=64$, $lr=5e-4$, $ent_coef=0.02$) 在 200,000 步内实现了接近收敛的学习效果 (图 2)。

训练过程可分为：

- **缓慢上升期** (0–200 回合)：均值从 29.3 逐步提升至 226.8，学习速度明显慢于 PPO；
- **波动求解期** (200–500 回合)：出现多次满分尖峰 (第 400 回合首次满分)，但策略不稳定，均值在 300–480 之间波动；
- **稳定提升期** (500–737 回合)：均值逐步提升，后 100 回合均值达 464.5，满分频率明显增加。

训练总回合 737，累计满分 161 次 (21.8%)。20 回合确定性评估均值 493.4 ± 20.8 ，达标率 90% (18/20)。A2C 虽未达到 PPO 的完美稳定度，但已具备强大的求解能力，与 PPO 的差距较小。




图 2: A2C 训练奖励曲线。绿色散点为原始奖励，曲线为 50 窗口移动平均。A2C 在训练后期接近收敛，后 100 回合均值 464.5。

2.4 传统控制方法对比

传统控制方法作为性能基线，从设计原理、实现方式和实验结果三个维度进行评估：

随机策略：每步以 50% 概率随机选择左移或右移，无任何反馈机制。作为性能下界，用于衡量任务固有难度。20 回合评估平均仅 16.1 步，标准差 6.8。

LQR 控制器：在平衡点 ($\theta = 0$) 附近对 CartPole 非线性动力学方程进行线性化，得到状态空间模型 $\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}u$ 。通过求解代数 Riccati 方程 $\mathbf{A}^T \mathbf{P} + \mathbf{P}\mathbf{A} - \mathbf{P}\mathbf{B}\mathbf{R}^{-1}\mathbf{B}^T \mathbf{P} + \mathbf{Q} = 0$ 获得最优反馈增益矩阵 $\mathbf{K}$ ，控制律为 $u = -\mathbf{K}\mathbf{x}$ 。权重矩阵设为 $\mathbf{Q} = \text{diag}(10, 1, 100, 1)$, $\mathbf{R} = 1$ ，重点惩罚角度偏差。20 回合评估均值 44.8 步。LQR 在

CartPole 上表现不佳的根本原因在于：该系统是强非线性的（摆杆角度可在 $\pm 15^\circ$ 范围内变化），而 LQR 仅在平衡点邻域内线性化，在大角度偏差时线性近似误差极大，导致控制力方向判断失误。

规则控制器：基于领域知识的启发式控制策略，控制规则为：

- 若摆杆向右倾斜 ($\theta > 0.05 \text{ rad}$) $\rightarrow$ 向右推
- 若摆杆向左倾斜 ($\theta < -0.05 \text{ rad}$) $\rightarrow$ 向左推
- 若角度较小，则根据角速度方向施加推力

该控制器无需建模，直接利用物理直觉设计。20 回合评估均值 215.8 步，远优于 LQR 和随机策略，证明在强非线性系统中，启发式规则可能超越基于线性化模型的最优控制。

表 2: 传统控制方法性能对比（20 回合评估）

方法	平均奖励	标准差	最高奖励	设计复杂度
随机策略	16.1	6.8	43	无
LQR 控制器	44.8	7.4	52	高（需建模 + 求解 Riccati）
规则控制器	215.8	29.1	293	低（启发式规则）

3 实验结果及分析

3.1 训练过程分析

3.1.1 PPO 训练过程分析

训练曲线分析。如图 1 所示，PPO 的奖励曲线呈现典型的 S 形增长，可清晰划分为三个阶段。探索期（0–200 回合）：奖励集中在 10–40 的低水平区间，散点均匀分布，说明智能体仍在随机尝试各种动作。收敛期（200–280 回合）：奖励从 40 陡峭攀升至 500，这一段的曲线斜率最大（每 10 回合平均提升约 80 分），是策略从随机到有目的控制的质变窗口。第 280 回合是关键转折点——首次达到满分 500，此后策略进入稳定状态。求解期（280 回合后）：奖励散点密集分布在 500 满分附近，仅 280–350 回合之间有少量回落（最低至 124 分），350 回合后几乎无任何回落，说明 PPO 的策略一旦收敛便不会退化。

多指标分析。图 6 从四个维度进一步揭示了 PPO 的收敛特性。

从图 6(a) 奖励曲线可见，PPO 的平滑曲线（蓝色）在约 300 回合处达到 500 后严格保持水平，这是算法收敛的理想标志。

从图 6(b) 滚动平均奖励（100 回合窗口）来看，均值从第 100 回合处的约 50 分匀速增长至第 300 回合处的 500 分，之后严格稳定在 500 分不变。这一单调递增且最终平稳的曲线形态，说明 PPO 的每步更新都在稳定地改善策略，没有出现性能倒退。

从图 6(c) 滚动成功率（以单回合奖励 ≥ 475 为达标）来看，成功率在 200–300 回合之间快速从 0% 跃升至 60% 以上，300 回合后稳定在 60%–100% 之间。值得注意的一

个细节是：即便在后期，成功率也并非 100%，在 60%–100% 之间波动。这意味着即使 PPO 已掌握完美策略，仍有约 20%–40% 的回合因初始状态（小车位置、摆杆角度的随机扰动）不同而未能达到满分。这反映了 CartPole 环境随机初始状态给完全稳定控制带来的固有挑战。

从图 6(d) 回合步数来看，求解期的步数密集分布在 500 步附近（满分），少量因失败提前终止的回合步数在 50–200 之间。回合步数的方差在后期显著减小，从探索期的 ± 200 步缩小至求解期的 ± 50 步以内，量化地证明了策略鲁棒性的提升。

训练总回合 737 回合，累计满分 161 次（21.8%）。20 回合确定性评估全部满分：均值 500.0 ± 0.0 ，达标率 100%。

3.1.2 A2C 训练过程分析

训练曲线分析。如图 2 所示，A2C 的奖励曲线呈现与 PPO 不同的多尖峰模式，而非平滑的 S 形。在 0–200 回合阶段，奖励散点均匀分布在 10–40 之间，与随机策略无明显差异，学习速度明显慢于 PPO。200 回合后开始出现零星高分（100–300 分），但回落频繁——前一回合可达 300 分，下一回合可能骤降至 20 分，反映出 A2C 不使用裁剪机制带来的策略不稳定性。第 400 回合首次达到满分 500，但并未像 PPO 那样从此稳定，而是继续经历多次“达到高分 → 回落 → 再达到高分”的循环。值得注意的是，后 100 回合均值达到 464.5，且满分尖峰的频率在训练后期明显增加，说明优化后的 A2C ($n_steps=64$, $lr=5e-4$) 正在接近收敛。

多指标分析。与 PPO 对照来看图 6 中 A2C 的指标曲线（绿色），差异显著。

从图 6(a) 奖励曲线可见，A2C 的平滑曲线呈阶梯状增长而非 PPO 的光滑递增，每级阶梯对应一次“策略突破期”，阶梯平台对应“回落调整期”。后 200 回合的曲线斜率明显增大，说明策略正在加速收敛。

从图 6(b) 滚动平均奖励来看，A2C 的滚动均值从约 30 分（100 回合处）缓慢增长至约 480 分（700 回合处）。与 PPO 的匀速增长不同，A2C 呈现明显的“突进-回落-再突进”阶梯状：200–400 回合均值约 150 分、400–550 回合均值约 250 分、550–700 回合均值约 380 分。每级阶梯的提升幅度逐渐增大。

从图 6(c) 滚动成功率来看，A2C 与 PPO 形成最鲜明的反差。PPO 的成功率在 300 回合后稳定在 60%–100%；A2C 的成功率在大部分训练时间内接近 0%，仅在后 200 回合才开始出现正值，且最终也不超过 30%。这一指标量化地说明：A2C 虽然在最后阶段能够偶尔达到满分，但其“可靠性”远不及 PPO——大部分回合仍会在中途失败。

从图 6(d) 回合步数来看，A2C 的回合步数在训练的大部分时间内集中在 30–160 步之间（对应奖励 30–150 分），后 200 回合才开始出现 500 步的满分回合，但频率不高且不连续。

训练总回合 737 回合，累计满分 161 次（21.8%）。20 回合确定性评估均值 493.4 ± 20.8 ，达标率 90%（18/20）。A2C 已具备强大的求解能力，但在稳定性上与 PPO 仍有差距。

3.2 训练前后控制效果

3.2.1 PPO 训练前后对比

如图 3 所示，PPO 训练前后的控制效果差距极为显著。

训练前（随机策略，灰色箱体），20 回合评估的中位数约 15 分，四分位距为 11–22 分，奖励分布集中在 10–40 分的狭窄区间内。这意味着随机策略下，摆杆平均只能保持约 15 步的平衡，最长不超过 43 步，完全不具有实际控制能力。

训练后（PPO，蓝色箱体），箱体完全压缩为单值 500 分（零方差），20 回合全部满分。从 15 分到 500 分，提升幅度超过 **31 倍**。更关键的是标准差从 6.8 降至 0——这不仅意味着策略有效，更意味着策略对不同的初始条件具有完全的鲁棒性。无论初始位置和角度如何扰动，PPO 都能在 500 步内保持摆杆不倒。

3.2.2 A2C 训练前后对比

同样如图 3 所示，A2C（绿色箱体）训练后的提升同样显著。

训练前（同一组随机策略数据）均值 15 分。训练后 A2C 的中位数达到 500 分，均值 493.4 分，提升幅度约 **31 倍**，与 PPO 接近。但与 PPO 的关键区别在于：A2C 的箱体并非压缩为单值，而是存在 3 个明显的异常值（离群点），分布在 60–130 分区间。这 3 个异常值对应 A2C 在 20 回合评估中未达标的 3 回合（达标率 90%）。标准差 20.8 也远高于 PPO 的 0。

这一对比揭示了一个重要结论：A2C 的策略能力（能达到多好）与 PPO 接近（中位数均为 500），但策略稳定性（能否稳定发挥）与 PPO 差距明显。在要求高可靠性的控制场景中，这一差距可能是决定性的。




图 3：训练前后 20 回合评估奖励分布。PPO（蓝色）箱体压缩为单值 500（零方差），提升 31 倍；A2C（绿色）中位数 500 但有 3 个异常值；随机策略（灰色）中位数约 15 分。散点为各回合个体数据。

3.3 对比结果

总体性能排序。如图 4 所示，五种控制方法的平均奖励（20 回合评估）排序为：**PPO**（500.0）> **A2C**（493.4） $\gg$ 规则控制器（215.8）> **LQR**（44.8）> 随机策略（16.1）。




图 4：五种控制方法平均奖励对比（20 回合评估，误差棒表示标准差）。红色虚线标注求解阈值（475）。PPO 以满分 500、零标准差位居第一；A2C 493.4 分、标准差 20.8 紧随其后；规则控制器 215.8 分是传统方法天花板。

从图 4 中可以读出以下关键信息：

第一，PPO 与 A2C 均跨越了求解阈值线（475 分，红色虚线），两者都具备了解决任务的能力。但 PPO 的柱体顶端正好在 500 分处且无误差棒（标准差 0），A2C 的柱体略低于 500（493.4 分）且有明显的误差棒（ ± 20.8 ）。两者的均值差距仅 1.4%（500 vs 493.4），但标准差差距是无限大（0 vs 20.8）——**PPO 的核心优势不在“能力”而在“稳定性”**。

第二，规则控制器（215.8 分）的柱体远低于求解阈值，但远高于 LQR（44.8 分）和随机策略（16.1 分）。其误差棒（ ± 29.1 ）是五种方法中最宽的，说明启发式规则在不同初始条件下表现起伏较大（最高 293 分、最低 188 分）。尽管如此，它仍然是传统方法中唯一能够在部分回合中坚持 200 步以上的方案。

第三，LQR（44.8 分）与随机策略（16.1 分）的柱体几乎贴地，两者均不具备实际控制能力。LQR 的 44.8 分略高于随机策略的 16.1 分（约 2.8 倍），但远低于规则控制器的 215.8 分——这直接说明了线性化最优控制在强非线性系统中的失效。CartPole 的摆杆可在 ± 15 ，而 LQR 仅在平衡点附近线性化，大角度偏差时线性近似误差极大。

训练速度对比。从图 5（PPO vs A2C 左右对比）可以直观比较两种 RL 算法的收敛速度差异。

Figure 4 | Training process comparison




图 5: PPO (左) 与 A2C (右) 训练过程左右对比。PPO 在约 280 回合平滑收敛至满分并持续保持；A2C 在约 400 回合首次满分但波动频繁，后 100 回合均值 464.5。

图 5 左图 (PPO) 的曲线在 280 回合处一次性地、平滑地跨越了 475 分阈值，此后不再回落。右图 (A2C) 的曲线在 400 回合处首次跨越阈值，但经历了多次“突破-回落”振荡。具体而言：PPO 首次满分在第 280 回合，A2C 首次满分在第 400 回合——PPO 比 A2C 快约 30%。但若从“稳定持续满分”的角度看，PPO 的第 280 回合也是稳定起点，而 A2C 直到训练结束 (737 回合) 仍未实现完全稳定。

传统控制方法不需要训练，这是其优势。但规则控制器 215.8 分和 LQR 44.8 分的表现说明：无需训练带来的便利是以性能大幅折损为代价的。

稳定性对比。稳定性从两个维度衡量：评估标准差和达标率。

表 3: 五种控制方法全面对比

方法	平均奖励	标准差	达标率	训练步数	是否收敛
随机策略	16.1	6.8	0%	0	否
LQR	44.8	7.4	0%	0	否 (模型失配)
规则控制	215.8	29.1	0%	0	否
A2C (优化)	493.4	20.8	90%	200,000	接近收敛
PPO	500.0	0.0	100%	200,000	完全收敛

PPO 的标准差 0 意味着其策略在不同初始条件下 100% 可靠——这是一个控制算法所能达到的最高稳定性水平。A2C 的标准差 20.8 虽然相比优化前 (89.8 分时标准差 7.4) 已大幅改善，但 90% 的达标率意味着每 10 次控制中有 1 次会意外失败，在要求高可靠性的工业场景中可能不可接受。

规则控制器的标准差 29.1 是五种方法中最高的，但其均值 215.8 分意味着即使“最差情况” (188 分) 也远好于 LQR 的“最好情况” (52 分)。这说明启发式规则虽然不够

精确，但具有稳定的基础控制能力。

最终效果排序。综合三个维度（训练速度、稳定性、最终效果），五种方法的总体排名为：

1. **PPO**：完美解决任务，唯一兼具高能力（500 分）和高稳定性（标准差 0）的方法。
2. **A2C**：能力接近 PPO（493.4 分），但稳定性不足（标准差 20.8，达标率 90%）。
3. **规则控制器**：传统方法中最优（215.8 分），无需训练，但远不及 RL 方法。
4. **LQR 控制器**：44.8 分，线性化模型在强非线性系统中基本失效。
5. **随机策略**：16.1 分，性能下界。

Figure 6 | Multi-metric training analysis




图 6：训练过程多指标对比面板。(a) 训练奖励曲线——PPO 平滑收敛至 500，A2C 阶梯状增长；(b) 100 回合移动平均奖励——PPO 单调递增后稳定，A2C 三段式阶梯攀升；(c) 100 回合滚动成功率——PPO 快速跃升至 60% 以上，A2C 后期才出现正值；(d) 回合步数——PPO 在 500 步密集分布，A2C 在 30-160 步间波动。

4 总结体会

本实验严格按任务描述实现了自定义 CartPole 环境（15、-10 失败惩罚），系统对比了五种控制方法。

核心结论：

1. PPO 以 500 满分、100% 达标率完美解决问题，是五种方法中的最优选择；
2. 优化后的 A2C ($n_steps=64$, $lr=5e-4$) 评估均值 493.4、达标率 90%，性能接近 PPO 但稳定性略逊；
3. 规则控制器 (215.8 分) 证明简单的领域知识可大幅超越线性化最优控制 (LQR, 44.8 分)；
4. 多指标分析 (奖励曲线、滚动均值、成功率、回合步数) 提供了比单一均值更全面的评估视角。

改进方向：可尝试 SAC 等更先进算法；进一步优化 A2C 网络结构；引入课程学习加速收敛。

代码仓库：<https://github.com/zhaihuahua78/cartpole-->

报告完成日期：2025 年 7 月