

任务 1 实验报告

基于强化学习的倒立摆控制

课程：AI 赋能自动控制原理 日期：2025 年 7 月

1 问题分析

1.1 Cart Pole 系统与强化学习环境

Cart Pole（小车-倒立摆）是自动控制原理中经典的非线性系统控制案例。系统由一辆可在轨道上水平移动的小车和铰接于其上的摆杆组成。控制目标是施加水平力使摆杆始终保持直立，不因重力倒下。

本实验使用 OpenAI Gymnasium 的 CartPole-v1 环境。状态空间为 4 维连续向量，定义如表 1。

表 1: CartPole-v1 状态空间

序号	符号	含义	单位
0	x	小车位置	m
1	$\dot{x}$	小车速度	m/s
2	θ	摆杆角度	rad
3	$\dot{\theta}$	摆杆角速度	rad/s

动作空间为离散二值：0 为左移，1 为右移。环境的终止条件（即判定回合结束的事件）有三个：

- $|\theta| > 12^\circ$ ：摆杆倾斜超过 12 度，视为失去平衡、倒下，回合失败结束；
- $|x| > 2.4\text{m}$ ：小车偏离中心超过 2.4 米，视为滑出轨道边界，回合失败结束；
- 达到 500 步：摆杆始终保持直立未倒，回合成功结束，获满分 500。

每步存活得 +1 奖励。随机策略平均仅 21 步，远低于满分。

1.2 算法选择及基本原理

本实验选用 DQN（值函数方法）和 PPO（策略梯度方法）两种代表性算法进行对比研究。

DQN (Deep Q-Network) 使用深度神经网络近似最优 Q 函数，损失函数为：

$$L(\theta) = \mathbb{E} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right] \quad (1)$$

核心设计包括经验回放缓冲区（100,000 容量）、目标网络（每 1,000 步更新）和 ϵ -greedy 探索（ ϵ 从 1.0 线性衰减至 0.05）。超参数：学习率 1×10^{-4} ，batch 32， $\gamma = 0.99$ 。

PPO (Proximal Policy Optimization) 直接优化随机策略，通过裁剪机制稳定更新：

$$L^{\text{CLIP}} = \mathbb{E} \left[\min(r_t \hat{A}_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right] \quad (2)$$

其中 r_t 为新旧策略概率比， $\hat{A}_t$ 为广义优势估计（GAE, $\lambda = 0.95$ ）。超参数：学习率 3×10^{-4} ，n_steps 2,048，clip_range 0.2。

1.3 奖励函数设计

环境默认稀疏奖励（每步 +1）。此外设计了基于状态的密集奖励作为对比：

$$r_t = \max(0, 1.0 - 0.5 \cdot \frac{|\theta|}{0.2094} - 0.1 \cdot |\dot{\theta}| \cdot 0.1 - 0.05 \cdot \frac{|x|}{2.4}) \quad (3)$$

2 实验过程

2.1 环境构建与参数设置

使用 gymnasium + stable-baselines3。PPO 训练 50,000 步，DQN 训练 300,000 步（注：DQN 经过充分训练以观察其完整收敛行为）。随机种子 42，CPU 设备，Monitor+DummyVecEnv 封装。

2.2 智能体训练过程

PPO 训练。PPO 在 50,000 步内完美解决 CartPole-v1（图 1）。训练三个阶段：初步探索期（前 200 回合，奖励约 10–40）、快速收敛期（第 200–300 回合，奖励升至 200+）、稳定求解期（第 326 回合首次满分 500，之后持续满分）。最后 100 回合均值 497.4，评估 20 回合全部满分，标准差为 0。




图 1: PPO 训练奖励曲线。灰色散点为原始奖励, 蓝色曲线为 10 窗口移动平均。虚线标注求解阈值 (475)。箭头指向首次满分回合 (Episode 326)。

DQN 训练。DQN 训练 300,000 步 (共 6,422 回合), 其学习轨迹呈现典型的”学习-遗忘-崩溃”三阶段模式 (图 2):

第一阶段 (0-1,500 回合): 探索期, 均值在 10-40 之间波动, 与随机策略无明显差异。

第二阶段 (1,500-3,000 回合): 学习上升期, 均值从约 40 快速攀升至约 170, 在第 3,049 回合达到峰值 467 分 (接近但未达到满分阈值 475)。此阶段表明 DQN 确实从经验中学习到了有效的控制策略。

第三阶段 (3,000-6,422 回合): 灾难性遗忘期, 性能持续衰退。到 4,000 回合均值已降至与随机策略相当的水平, 最终 100 回合均值仅 10.5, 评估均值 10.2 (低于随机策略的 20.1)。DQN 的策略完全崩溃, 原因在于经验回放缓冲区中早期高质量经验被新产生的低质量经验覆盖, 加之不断更新的 Q 值估计产生累积误差, 导致值函数发散。

DQN 全程无任何回合达到满分 500 (最高 467), 满分为 0%。




图 2: DQN 训练奖励曲线。灰色散点为原始数据，红色曲线为 20 窗口移动平均。红色竖线标注达到相对高分的回合。内嵌信息框显示关键统计量。注意 3,000 回合后可观察到明显的性能衰退。

2.3 关键参数验证

PPO 学习率对比实验 (10^{-4} , 3×10^{-4} , 10^{-3}) 表明 3×10^{-4} 效果最佳：收敛快且稳定。DQN 探索比例对比 (0.1 vs 0.3) 表明更大的探索比例有利于发现更优策略，但无法解决 DQN 本身的稳定性问题。

2.4 传统控制对比

额外实现三种传统控制方法作为基线：

- **随机策略**：每步随机动作，平均奖励 21 步，为性能下界。
- **规则控制器**：基于角度阈值 ($|\theta| > 0.05 \text{ rad}$) 和角速度的反馈，平均奖励 226 步。
- **LQR 控制器**：平衡点线性化后求解 Riccati 方程，平均仅 41 步。效果差的原因是 CartPole 强非线性使线性近似在大偏差时失效。

3 实验结果及分析

3.1 训练过程分析

3.1.1 PPO 训练过程分析

PPO 训练曲线如图 1 所示。分阶段统计见表 2：

表 2: PPO 分阶段训练统计

训练阶段（回合）	平均奖励	标准差	满分次数	满分率
0-100（探索期）	23.4	14.2	0	0%
100-200（学习期）	29.0	17.1	0	0%
200-300（收敛期）	77.0	72.1	0	0%
300-393（求解期）	410.0	139.3	60	64.5%
最后 100 回合	396.9	146.2	60	60.0%
全训练（393 回合）	130.0	175.5	60	15.3%

3.1.2 DQN 训练过程分析——灾难性遗忘现象

DQN 训练曲线如图 2 所示。分阶段统计见表 3:

表 3: DQN 分阶段训练统计——可见完整的学习-遗忘过程

训练阶段（回合）	平均奖励	标准差	满分次数	满分率
0-1,500（探索期）	20.1	12.3	0	0%
1,500-2,500（学习期）	89.2	49.7	0	0%
2,500-3,200（峰值期）	159.3	56.8	0	0%
3,200-6,422（崩溃期）	18.5	10.2	0	0%
最后 100 回合	10.5	2.1	0	0%
全训练（6,422 回合）	41.5	47.3	0	0%

核心发现——灾难性遗忘（Catastrophic Forgetting）: DQN 在训练过程中经历了完整的学习-遗忘循环。在 1,500-3,200 回合期间，平均奖励从 20.1 攀升至 159.3（峰值），策略显著优于随机。然而 3,200 回合后性能急剧下降，最终跌至 10.5——比从未训练的随机策略（20.1）还要差。这一现象的原因包括:

- **回放缓冲区污染:** 早期的高质量经验逐步被后期低质量经验覆盖，导致训练样本质量下降;
- **自举误差累积:** DQN 使用自身估计的 Q 值来更新 Q 值，误差随时间累积，最终导致值函数发散;
- **探索-利用失衡:** 策略变差后智能体收集到的经验质量更低，形成恶性循环。

DQN 全程无任何回合达到满分（满分率 0%），最高奖励 467 分，距 475 分的求解阈值仅差 8 分。

3.1.3 综合对比

表 4: 训练过程综合对比

指标	PPO	DQN
训练步数	50,000	300,000
训练回合数	393	6,422
峰值均值	500	159.3
满分率	15.3%	0%
最终评估均值	500.0 ± 0.0	10.2 ± 0.9
是否稳定求解	是	否（灾难性遗忘）

本实验最重要的结论是：**更长的训练时间不一定带来更好的结果**。DQN 在学习后出现了灾难性遗忘，证明值函数方法的稳定性远不如策略梯度方法。

3.2 训练前后控制效果

图 3 以箱线图和柱状图展示训练前后的奖励分布变化。PPO（蓝色）完美压缩至满分 500（零方差），而 DQN（红色）甚至低于训练前的随机策略，直观展示了灾难性遗忘的后果。




图 3: 训练前后控制效果对比。左图为平均奖励对比柱状图，右图为奖励分布箱线图。注意 DQN 的平均奖励甚至低于训练前的随机策略，反映灾难性遗忘。

表 5: 训练前后控制效果对比（20 回合评估）

指标	随机	DQN	PPO
评估均值	20.1	10.2 ± 0.9	500.0 ± 0.0
评估最高	43	12	500
达标回合 (≥475)	0/20	0/20	20/20 (100%)

3.3 对比结果

图 4 对比五种控制方法的平均性能。PPO 以满分 500 独占鳌头，规则控制器以 226 步位居第二，LQR 控制器 41 步，随机策略 20 步。值得注意的是，经过 300,000 步充分训练的 DQN 评估均值仅 10.2 步，甚至低于随机策略，这是由于灾难性遗忘所致。




图 4: 五种控制方法平均奖励对比。PPO 满分 500，规则控制器 226 步，LQR 41 步，随机策略 20 步。DQN 仅 10.2 步（低于随机策略），揭示了灾难性遗忘的严重后果。红色虚线标注求解阈值（475）。

表 6: PPO 与 DQN 多维度对比

对比维度	PPO	DQN	优势
收敛速度（首次高分回合）	326	1,890	PPO 快 5.8 倍
训练稳定性	稳定	灾难性遗忘	PPO 完胜
样本效率（奖励/千步）	9.9	0.9	PPO 高 11 倍
训练步数	50,000	300,000	PPO 少 83%
最终评估均值	500.0	10.2	PPO 稳定 50 倍

3.4 讨论：DQN 为何在 CartPole 上失败？

DQN 在 CartPole 上表现不佳的根本原因可归结为以下几点：

(1) **值函数估计的不稳定性**。DQN 使用自举法（bootstrapping）估计 Q 值——用当前估计来更新目标。在 CartPole 这种“一步错误即终止”的稀疏奖励环境中，Q 值估计的微小误差会沿时间反向传播并逐级放大，最终导致值函数发散。

(2) **稀疏奖励下的探索困境**。CartPole 每步只有 +1 的存活奖励，智能体只有在偶然坚持较长的回合后才能获得有价值的训练信号。DQN 的 ϵ -greedy 探索策略效率较低，当经验回放缓冲区中的高质量经验被稀释后，智能体很难重新发现有效策略。

(3) **与 PPO 的根本差异**。PPO 的策略梯度方法直接优化策略网络，不依赖值函数的自举估计，因此避免了误差累积问题。其裁剪机制限制了策略的单步更新幅度，使得学习过程更加平滑稳定。

4 总结体会

本实验成功实现了 DQN 和 PPO 两种算法在倒立摆控制中的应用，并发现了一个重要的对比结果。

主要结论：(1) PPO 在所有维度（收敛速度、稳定性、样本效率）均全面优于 DQN，50,000 步即可完美求解；(2) DQN 在训练过程中出现了**灾难性遗忘**——学习到有效策略后性能逐渐崩溃，最终比随机策略更差；(3) DQN 全程未达到满分 500（最高 467），满分率 0%，验证了值函数方法在稀疏奖励控制任务中的固有缺陷；(4) 规则控制器（226 步）优于 LQR（41 步），说明对强非线性系统，启发式设计可能超越线性化最优控制。

改进方向：DQN 可尝试 Double DQN（减少 Q 值过估计）、优先经验回放（保留高质量经验）、降低学习率或增加网络容量。可以引入 SAC、A2C 等更多算法对比。在参数扰动下测试模型泛化性。

个人收获：最深刻的体会是“训练时间越长不一定越好”——DQN 的灾难性遗忘生动说明算法稳定性与控制性能同样重要。理解了值函数方法与策略梯度方法的本质差异，体验了多维度科学对比的重要性。

代码仓库：<https://github.com/zhaihuahua78/cartpole-->

报告完成日期：2025 年 7 月