

任务 1 实验报告

基于强化学习的倒立摆控制

课程：AI 赋能自动控制原理 日期：2025 年 7 月

1 问题分析

1.1 Cart Pole 系统与强化学习环境

Cart Pole（小车-倒立摆）是自动控制原理中经典的非线性系统控制案例。系统由一辆可在轨道上水平移动的小车和铰接于其上的摆杆组成。控制目标是施加水平力使摆杆始终保持直立。

本实验使用符合任务描述的自定义 CartPole 环境，基于 OpenAI Gymnasium 的物理引擎实现，修改了以下参数：

- 终止角度：**由 CartPole-v1 默认的 12° 改为 15° (0.2618 rad)，与任务描述一致；
- 失败惩罚：**当摆杆倾斜超过 15° 或小车超出轨道时，给予 **-10** 的惩罚，与任务描述“获得相应的负向惩罚”一致；
- 每步存活奖励 +1、小车边界 2.4m、最大步数 500 保持不变。

状态空间为 4 维连续向量，定义如表 1。

表 1: 自定义 CartPole 环境状态空间

序号	符号	含义	单位
0	x	小车位置	m
1	$\dot{x}$	小车速度	m/s
2	θ	摆杆角度	rad
3	$\dot{\theta}$	摆杆角速度	rad/s

动作空间为离散二值：0 为左移，1 为右移。环境的终止条件：摆杆倒下 ($|\theta| > 15^\circ$)、小车出轨 ($|x| > 2.4 \text{ m}$)、或成功坚持 500 步。

1.2 算法选择及基本原理

本实验选用 DQN（值函数方法）和 PPO（策略梯度方法）两种代表性算法进行对比研究。

DQN (Deep Q-Network) 使用深度神经网络近似最优 Q 函数，损失函数为：

$$L(\theta) = \mathbb{E} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right] \quad (1)$$

核心设计包括经验回放缓冲区（100,000 容量）、目标网络（每 1,000 步更新）和 ϵ -greedy 探索。超参数：学习率 1×10^{-4} ，batch 32， $\gamma = 0.99$ 。

PPO (Proximal Policy Optimization) 直接优化随机策略，通过裁剪机制稳定更新：

$$L^{\text{CLIP}} = \mathbb{E} \left[\min(r_t \hat{A}_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right] \quad (2)$$

超参数：学习率 3×10^{-4} ，n_steps 2,048，clip_range 0.2，GAE $\lambda = 0.95$ 。

1.3 奖励函数设计

奖励函数设计是本次实验的核心环节。根据任务描述要求，奖励规则如下：

- 每步成功保持平衡： $r = +1$ （正向奖励）
- 失败（ $\theta > 15^\circ$ 或 $x > 2.4\text{m}$ ）： $r = -10$ （负向惩罚）
- 成功坚持 500 步： $r = +1$ （与每步一致，不做额外加分）

2 实验过程

2.1 环境构建与参数设置

使用自定义 CartPole 环境（自实现物理引擎，与 Gymnasium CartPole-v1 一致）。PPO 训练 100,000 步，DQN 训练 300,000 步。随机种子 42，CPU 设备。

2.2 PPO 训练过程

PPO 在 100,000 步内完美求解自定义环境（图 1）。训练过程：- 探索期（0-200 回合）：奖励 10-40，与随机策略相当 - 收敛期（200-280 回合）：奖励快速攀升至 500 - 稳定求解期（280 回合后）：持续满分 500




图 1: PPO（右）与 DQN（左）在自定义环境中的训练曲线。PPO 稳定收敛至满分，DQN 经历了完整的学习-遗忘过程。

训练汇总：总回合 434，最后 100 回合均值 **500.0**，最高奖励 500。20 回合评估全部满分（500.0±0.0）。

2.3 DQN 训练过程

DQN 训练 300,000 步（共 7,711 回合），呈现三阶段模式（图??）：

- 探索期（0–1,200 回合）：均值 10–20，与随机策略无异
- 学习上升期（1,200–2,200 回合）：均值从 20 攀升至峰值 389（第 2,200 回合）
- 灾难性遗忘期（2,200 回合后）：性能持续衰退至均值 2–5，评估仅 2.0

DQN 未达到满分，满分率 0%。失败惩罚（-10）加速了遗忘过程：策略变差后频繁获得负奖励，导致 Q 值快速发散。

2.4 传统控制对比

- 随机策略：平均 12.3 步
- 规则控制器：基于角度阈值反馈，平均 215.8 步
- LQR 控制器：线性化最优控制，平均 44.8 步

3 实验结果及分析

3.1 控制方法综合对比

表 2：五种控制方法在自定义环境中的性能对比（20 回合评估）

方法	平均奖励	标准差	最高奖励	达标率
随机策略	12.3	9.8	43	0%
LQR 控制器	44.8	18.2	52	0%
规则控制器	215.8	31.5	293	0%
DQN（30 万步）	2.0	1.1	4	0%
PPO（10 万步）	500.0	0.0	500	100%




图 2: 五种控制方法平均奖励对比。PPO 满分 500，规则控制器 216 步，LQR 45 步，DQN 仅 2 步（灾难性遗忘）。

3.2 灾难性遗忘分析

DQN 在自定义环境中的灾难性遗忘比标准 CartPole-v1 更加严重（评估均值 2.0 vs 10.2），原因在于失败惩罚（-10）形成了恶性循环：

1. DQN 学到一定策略后 Q 值估计开始发散
2. 策略退化导致频繁触碰 15° 边界
3. -10 惩罚压低 Q 值估计，进一步恶化策略
4. 回放缓冲区中高质量经验被低质量经验覆盖
5. 最终策略完全崩溃

3.3 PPO 与 DQN 根本差异

PPO 成功而 DQN 失败的核心原因：

- PPO 直接优化策略网络，不依赖 Q 值自举估计，避免误差累积
- PPO 的裁剪机制限制单步更新幅度，保证学习稳定性
- DQN 的 ϵ -greedy 探索在负惩罚环境下效率极低

4 总结体会

本实验严格按照任务描述实现了自定义 CartPole 环境（15° 终止角、-10 失败惩罚），并对比了五种控制方法。

核心结论： (1) PPO 完美解决自定义环境（100% 达标率，500 满分），展示了策略梯度方法的卓越稳定性和样本效率；(2) DQN 出现灾难性遗忘（评估均值 2.0），在失败

惩罚机制下遗忘速度更快、程度更深；(3)规则控制器（215.8 分）优于 LQR（44.8 分），对强非线性系统启发式设计优于线性化最优控制。

对任务描述的验证：实验证明 15° 终止角和-10 惩罚的设计是合理的——PPO 能够学会在该约束下完美控制，而 DQN 的失败则凸显了算法选择对控制性能的决定性影响。

改进方向：引入 Double DQN、优先经验回放等改进 DQN；尝试 SAC、A2C 等更多算法；在参数扰动下测试泛化性。

代码仓库：<https://github.com/zhaihuahua78/cartpole-->

报告完成日期：2025 年 7 月