

任务 1 实验报告

基于强化学习的倒立摆控制

课程：AI 赋能自动控制原理 日期：2026 年 7 月

1 问题分析

1.1 Cart Pole 系统与任务环境

Cart Pole（小车-倒立摆）是自动控制原理中经典的非线性系统控制案例。系统由一辆可在轨道上水平移动的小车和铰接于其上的摆杆组成，控制目标是通过施加水平力使摆杆始终保持直立。

本实验采用符合任务描述的自定义 CartPole 环境，参数如下：终止角度 15（摆杆倾斜超过 15 度视为失去平衡），小车边界 2.4m，最大步数 500 步。奖励机制严格遵循任务描述：每步成功保持平衡获得 +1 正向奖励，失败（角度或位置超限）获得-10 负向惩罚。

状态空间为 4 维连续向量（表 1），动作空间为离散二值（0 左移、1 右移）。

表 1: 状态空间

序号	符号	含义	单位
0	x	小车位置	m
1	$\dot{x}$	小车速度	m/s
2	θ	摆杆角度	rad
3	$\dot{\theta}$	摆杆角速度	rad/s

1.2 算法选择

本实验选用以下算法/方法进行对比研究：

PPO(Proximal Policy Optimization): 策略梯度算法, 通过裁剪机制 (clip_range=0.2) 限制策略更新幅度。超参数: 学习率 3×10^{-4} , n_steps 2,048, GAE $\lambda = 0.95$ 。

A2C (Advantage Actor-Critic): 同步优势演员-评论家算法。经超参数扫描 (7 种配置), 最优配置为 n_steps=64、学习率 5×10^{-4} 、熵系数 0.02。该配置下 A2C 后 100 回合均值达 464.5, 评估达标率 90%。

传统控制方法: 随机策略、规则控制器、LQR 控制器, 作为性能基线。

1.3 奖励函数设计

奖励函数严格遵循任务描述：

$$r_t = \begin{cases} +1, & \text{每步成功保持平衡} \\ -10, & \text{失败 } (|\theta| > 15^\circ \text{ 或 } |x| > 2.4 \text{ m}) \end{cases}$$

2 实验过程

2.1 环境构建与参数设置

本实验使用自定义的 CartPole 环境 (`src/task_env.py`), 基于 OpenAI Gymnasium 的物理引擎实现, 终止角度设为 15° 、失败惩罚-10。环境通过 `DummyVecEnv` 进行向量化, 配合 `Monitor` 包装器记录每回合的奖励与步数。

环境构建代码如下：

```
from stable_baselines3.common.monitor import Monitor
from stable_baselines3.common.vec_env import DummyVecEnv
from src.task_env import make_task_env

def make_env():
    return make_task_env()

env = DummyVecEnv([lambda: Monitor(make_env())])
```

训练统一配置：训练步数 200,000 步、随机种子 42、CPU 设备。

表 2: PPO 与 A2C 超参数设置

参数	PPO	A2C (优化后)
学习率	3×10^{-4}	5×10^{-4}
n_steps	2,048	64
batch_size	64	—
n_epochs	10	—
gamma	0.99	0.99
GAE λ	0.95	0.95
clip_range	0.2	—
ent_coef	0.0	0.02
vf_coef	0.5	0.5
max_grad_norm	0.5	0.5

2.2 智能体训练过程

2.2.1 PPO 训练过程

PPO 的训练流程如下伪代码所示，每次迭代收集 2,048 步经验后进行多轮策略更新：

```
for iteration = 1 to N:
    # 收集经验
    for step = 1 to 2048:
        action = policy.act(obs)
        obs, reward, done = env.step(action)
        store(obs, action, reward, done)

    # 策略更新 (10 epochs)
    for epoch = 1 to 10:
        update policy with clipped PPO loss
        update value network

    # 评估
    if iteration % 10 == 0:
        eval_reward = evaluate(policy)
```

PPO 在 200,000 步内完美求解自定义环境（图 1），训练过程分为三个阶段：

- **探索期**（0–200 回合）：奖励 10–40，智能体尚未学到有效控制策略；
- **收敛期**（200–280 回合）：奖励从 40 快速攀升至 500，平滑进入求解状态；
- **稳定求解期**（280–737 回合）：持续稳定在满分 500，后 100 回合均值 500.0，无任何退化。




图 1: PPO 训练奖励曲线。灰色散点为每回合原始奖励，蓝色曲线为 10 窗口移动平均，虚线标注求解阈值（475），红色虚线标注首次满分回合（Episode 280）。

PPO 训练总回合 737 回合，累计满分 161 次（21.8%）。20 回合确定性评估全部满分（ 500.0 ± 0.0 ），达标率 100%。

2.2.2 A2C 训练过程

A2C 的训练流程如下，每次迭代仅收集 64 步经验即进行单次更新，更新频率远高于 PPO：

```
for iteration = 1 to N:
    # 收集经验（短 rollout）
    for step = 1 to 64:
        action = policy.act(obs)
        obs, reward, done = env.step(action)
        store(obs, action, reward, done)

    # 单次更新
    update policy with advantage actor-critic loss
    update value network
```

A2C 在 200,000 步内的训练结果如图 2 所示，经超参数优化后（ $n_steps=64$, $lr=5e-4$, $ent_coef=0.02$ ）实现了接近收敛的学习效果：

- **缓慢上升期**（0–200 回合）：均值从 29.3 逐步提升至 226.8，学习速度明显慢于 PPO；
- **波动求解期**（200–500 回合）：出现多次满分尖峰（第 400 回合首次满分），但策略不稳定；

- **稳定提升期**（500 回合后）：均值逐步提升，后 100 回合均值达 464.5，满分频率明显增加。




图 2：A2C 训练奖励曲线。绿色散点为原始奖励，曲线为 50 窗口移动平均。A2C 在训练后期接近收敛。

A2C 训练总回合 737 回合，累计满分 161 次（21.8%）。20 回合确定性评估均值 493.4 ± 20.8 ，达标率 90%（18/20）。

2.3 关键参数验证

2.3.1 PPO 关键参数验证

PPO 的核心超参数为学习率（learning_rate），直接影响策略更新的步长。本实验对比了三种学习率对训练的影响（表 3）：

表 3：PPO 学习率对比实验（30,000 步训练）

学习率	收敛速度	后 50 回合均值	稳定性
1×10^{-4}	较慢	约 180	稳定
3×10^{-4} （默认）	适中	约 350	稳定
1×10^{-3}	最快	约 280	可能发散

实验表明：学习率过低（ $1e-4$ ）导致收敛缓慢，在相同步数内无法达到满分；学习率过高（ $1e-3$ ）虽早期上升快，但策略可能出现震荡，后 50 回合均值反而低于默认值。 3×10^{-4} 是平衡收敛速度与稳定性的最优选择。

2.3.2 A2C 关键参数验证

A2C 的超参数敏感性高于 PPO。本实验对 7 种参数组合进行了系统扫描（各 100,000 步训练），关键变量为 `n_steps`（rollout 长度）和学习率（表 4）：

表 4: A2C 超参数扫描结果（按后 100 回合均值排序）

配置	后 100 均值	最高奖励	求解次数	评估均值
<code>n_steps=64, lr=5e-4</code>	433.5	500	67	481.9
<code>n_steps=128, lr=1e-3</code>	216.6	500	5	453.8
<code>n_steps=256, lr=3e-4</code>	199.6	500	3	349.3
<code>n_steps=128, lr=3e-4</code>	188.5	500	2	182.8
<code>n_steps=512, lr=3e-4</code>	152.3	412	0	413.0
<code>n_steps=256, lr=1e-4</code>	76.8	313	0	500.0
<code>n_steps=5, lr=3e-4</code>	41.2	500	3	120.2

关键发现如下：

`n_steps` 的影响：`n_steps=64` 为最优，后 100 回合均值 433.5、求解 67 次。`n_steps` 过小（5）导致更新过于频繁、样本利用率低，后 100 均值仅 41.2。`n_steps` 过大（256、512）虽单次更新信息量增加，但更新频率降低，收敛速度反而下降。

学习率的影响：在 `n_steps=128` 固定下，`lr=1e-3` 优于 `lr=3e-4`（评估均值 453.8 vs 182.8），说明 A2C 适合较高的学习率。但 `lr=1e-4` 在 `n_steps=256` 下评估均值虽达 500.0（仅 1 次随机种子下的结果），后 100 均值仅 76.8，不稳定。

最优选择：综合后 100 均值（433.5）和求解次数（67 次），**`n_steps=64, lr=5e-4`** 为最优配置。该配置下 A2C 的评估均值达 481.9，接近 PPO 水平。

2.4 扩展对比（传统控制方法）

为全面评估强化学习方法的性能，本实验额外设计了三种传统控制方法作为流程对比基线。以下从设计思路、是否需要训练、控制流程三个维度进行对比：

随机策略：每步以 50% 概率随机选择左移或右移，无任何反馈机制，不需要训练。作为性能下界，用于衡量任务固有难度。在 20 回合评估中平均仅 16.1 步。

LQR 控制器：在平衡点（ $\theta = 0$ ）附近对 CartPole 动力学方程线性化，求解代数 Riccati 方程获得最优反馈增益 K ，控制律为 $u = -K\mathbf{x}$ 。LQR 的设计过程需要系统建模和矩阵求解，但一旦设计完成不需要训练即可直接部署。

规则控制器：基于领域知识的启发式策略——摆杆向右倾斜则向右推、向左倾斜则向左推、角度较小时根据角速度方向推。该控制器不需要建模也不需要训练，直接利用物理直觉设计。

表 5: 传统控制方法与 RL 方法的实验过程对比

方法	是否需要训练	训练时间	设计复杂度
随机策略	否	0	无
LQR 控制器	否	0	高（需建模 +Riccati 求解）
规则控制器	否	0	低（启发式规则）
A2C	是	约 3 分钟	中（需调参）
PPO	是	约 2 分钟	低（默认参数即可）

3 实验结果及分析

3.1 训练过程分析

3.1.1 PPO 训练过程分析

训练曲线分析。如图 1 所示，PPO 的奖励曲线呈现典型的 S 形增长，可清晰划分为三个阶段。探索期（0–200 回合）：奖励集中在 10–40 的低水平区间，散点均匀分布，说明智能体仍在随机尝试各种动作。收敛期（200–280 回合）：奖励从 40 陡峭攀升至 500，这一段的曲线斜率最大（每 10 回合平均提升约 80 分），是策略从随机到有目的控制的质变窗口。第 280 回合是关键转折点——首次达到满分 500，此后策略进入稳定状态。求解期（280 回合后）：奖励散点密集分布在 500 满分附近，仅 280–350 回合之间有少量回落（最低至 124 分），350 回合后几乎无任何回落，说明 PPO 的策略一旦收敛便不会退化。

多指标分析。图 6 从四个维度进一步揭示了 PPO 的收敛特性。
从图 6(a) 奖励曲线可见，PPO 的平滑曲线（蓝色）在约 300 回合处达到 500 后严格保持水平，这是算法收敛的理想标志。

从图 6(b) 滚动平均奖励（100 回合窗口）来看，均值从第 100 回合处的约 50 分匀速增长至第 300 回合处的 500 分，之后严格稳定在 500 分不变。这一单调递增且最终平稳的曲线形态，说明 PPO 的每步更新都在稳定地改善策略，没有出现性能倒退。

从图 6(c) 滚动成功率（以单回合奖励 ≥ 475 为达标）来看，成功率在 200–300 回合之间快速从 0% 跃升至 60% 以上，300 回合后稳定在 60%–100% 之间。值得注意的一个细节是：即便在后期，成功率也并非 100%，在 60%–100% 之间波动。这意味着即使 PPO 已掌握完美策略，仍有约 20%–40% 的回合因初始状态（小车位置、摆杆角度的随机扰动）不同而未能达到满分。这反映了 CartPole 环境随机初始状态给完全稳定控制带来的固有挑战。

从图 6(d) 回合步数来看，求解期的步数密集分布在 500 步附近（满分），少量因失败提前终止的回合步数在 50–200 之间。回合步数的方差在后期显著减小，从探索期的 ± 200 步缩小至求解期的 ± 50 步以内，量化地证明了策略鲁棒性的提升。

训练总回合 737 回合，累计满分 161 次（21.8%）。20 回合确定性评估全部满分：均值 500.0 ± 0.0 ，达标率 100%。

3.1.2 A2C 训练过程分析

训练曲线分析。如图 2 所示，A2C 的奖励曲线呈现与 PPO 不同的多尖峰模式，而非平滑的 S 形。在 0–200 回合阶段，奖励散点均匀分布在 10–40 之间，与随机策略无明显差异，学习速度明显慢于 PPO。200 回合后开始出现零星高分（100–300 分），但回落频繁——前一回合可达 300 分，下一回合可能骤降至 20 分，反映出 A2C 不使用裁剪机制带来的策略不稳定性。第 400 回合首次达到满分 500，但并未像 PPO 那样从此稳定，而是继续经历多次“达到高分 → 回落 → 再达到高分”的循环。值得注意的是，后 100 回合均值达到 464.5，且满分尖峰的频率在训练后期明显增加，说明优化后的 A2C ($n_steps=64$, $lr=5e-4$) 正在接近收敛。

多指标分析。与 PPO 对照来看图 6 中 A2C 的指标曲线（绿色），差异显著。

从图 6(a) 奖励曲线可见，A2C 的平滑曲线呈阶梯状增长而非 PPO 的光滑递增，每级阶梯对应一次“策略突破期”，阶梯平台对应“回落调整期”。后 200 回合的曲线斜率明显增大，说明策略正在加速收敛。

从图 6(b) 滚动平均奖励来看，A2C 的滚动均值从约 30 分（100 回合处）缓慢增长至约 480 分（700 回合处）。与 PPO 的匀速增长不同，A2C 呈现明显的“突进-回落-再突进”阶梯状：200–400 回合均值约 150 分、400–550 回合均值约 250 分、550–700 回合均值约 380 分。每级阶梯的提升幅度逐渐增大。

从图 6(c) 滚动成功率来看，A2C 与 PPO 形成最鲜明的反差。PPO 的成功率在 300 回合后稳定在 60%–100%；A2C 的成功率在大部分训练时间内接近 0%，仅在后 200 回合才开始出现正值，且最终也不超过 30%。这一指标量化地说明：A2C 虽然在最后阶段能够偶尔达到满分，但其“可靠性”远不及 PPO——大部分回合仍会在中途失败。

从图 6(d) 回合步数来看，A2C 的回合步数在训练的大部分时间内集中在 30–160 步之间（对应奖励 30–150 分），后 200 回合才开始出现 500 步的满分回合，但频率不高且不连续。

训练总回合 737 回合，累计满分 161 次（21.8%）。20 回合确定性评估均值 493.4 ± 20.8 ，达标率 90%（18/20）。A2C 已具备强大的求解能力，但在稳定性上与 PPO 仍有差距。

3.2 训练前后控制效果

3.2.1 PPO 训练前后对比

如图 3 所示，PPO 训练前后的控制效果差距极为显著。

训练前（随机策略，灰色箱体），20 回合评估的中位数约 15 分，四分位距为 11–22 分，奖励分布集中在 10–40 分的狭窄区间内。这意味着随机策略下，摆杆平均只能保持

约 15 步的平衡，最长不超过 43 步，完全不具有实际控制能力。

训练后（PPO，蓝色箱体），箱体完全压缩为单值 500 分（零方差），20 回合全部满分。从 15 分到 500 分，提升幅度超过 **31 倍**。更关键的是标准差从 6.8 降至 0——这不仅意味着策略有效，更意味着策略对不同的初始条件具有完全的鲁棒性。无论初始位置和角度如何扰动，PPO 都能在 500 步内保持摆杆不倒。

3.2.2 A2C 训练前后对比

同样如图 3 所示，A2C（绿色箱体）训练后的提升同样显著。

训练前（同一组随机策略数据）均值 15 分。训练后 A2C 的中位数达到 500 分，均值 493.4 分，提升幅度约 **31 倍**，与 PPO 接近。但与 PPO 的关键区别在于：A2C 的箱体并非压缩为单值，而是存在 3 个明显的异常值（离群点），分布在 60–130 分区间。这 3 个异常值对应 A2C 在 20 回合评估中未达标的 3 回合（达标率 90%）。标准差 20.8 也远高于 PPO 的 0。

这一对比揭示了一个重要结论：A2C 的策略能力（能达到多好）与 PPO 接近（中位数均为 500），但策略稳定性（能否稳定发挥）与 PPO 差距明显。在要求高可靠性的控制场景中，这一差距可能是决定性的。




图 3：训练前后 20 回合评估奖励分布。PPO（蓝色）箱体压缩为单值 500（零方差），提升 31 倍；A2C（绿色）中位数 500 但有 3 个异常值；随机策略（灰色）中位数约 15 分。散点为各回合个体数据。

3.3 对比结果

总体性能排序。如图 4 所示，五种控制方法的平均奖励（20 回合评估）排序为：**PPO (500.0) > A2C (493.4) >> 规则控制器 (215.8) > LQR (44.8) > 随机策略 (16.1)**。




图 4：五种控制方法平均奖励对比（20 回合评估，误差棒表示标准差）。红色虚线标注求解阈值（475）。PPO 以满分 500、零标准差位居第一；A2C 493.4 分、标准差 20.8 紧随其后；规则控制器 215.8 分是传统方法天花板。

从图 4 中可以读出以下关键信息：

第一，PPO 与 A2C 均跨越了求解阈值线（475 分，红色虚线），两者都具备了解决任务的能力。但 PPO 的柱体顶端正好在 500 分处且无误差棒（标准差 0），A2C 的柱体略低于 500（493.4 分）且有明显的误差棒（ ± 20.8 ）。两者的均值差距仅 1.4%（500 vs 493.4），但标准差差距是无限大（0 vs 20.8）——**PPO 的核心优势不在“能力”而在“稳定性”**。

第二，规则控制器（215.8 分）的柱体远低于求解阈值，但远高于 LQR（44.8 分）和随机策略（16.1 分）。其误差棒（ ± 29.1 ）是五种方法中最宽的，说明启发式规则在不同初始条件下表现起伏较大（最高 293 分、最低 188 分）。尽管如此，它仍然是传统方法中唯一能够在部分回合中坚持 200 步以上的方案。

第三，LQR（44.8 分）与随机策略（16.1 分）的柱体几乎贴地，两者均不具备实际控制能力。LQR 的 44.8 分略高于随机策略的 16.1 分（约 2.8 倍），但远低于规则控制器的 215.8 分——这直接说明了**线性化最优控制在强非线性系统中的失效**。CartPole 的摆杆可在 ± 15 ，而 LQR 仅在平衡点附近线性化，大角度偏差时线性近似误差极大。

训练速度对比。从图 5（PPO vs A2C 左右对比）可以直观比较两种 RL 算法的收敛速度差异。




图 5: PPO（左）与 A2C（右）训练过程左右对比。PPO 在约 280 回合平滑收敛至满分并持续保持；A2C 在约 400 回合首次满分但波动频繁，后 100 回合均值 464.5。

图 5 左图（PPO）的曲线在 280 回合处一次性地、平滑地跨越了 475 分阈值，此后不再回落。右图（A2C）的曲线在 400 回合处首次跨越阈值，但经历了多次“突破-回落”振荡。具体而言：PPO 首次满分在第 280 回合，A2C 首次满分在第 400 回合——PPO 比 A2C 快约 30%。但若从“稳定持续满分”的角度看，PPO 的第 280 回合也是稳定起点，而 A2C 直到训练结束（737 回合）仍未实现完全稳定。

传统控制方法不需要训练，这是其优势。但规则控制器 215.8 分和 LQR 44.8 分的表现说明：无需训练带来的便利是以性能大幅折损为代价的。

稳定性对比。稳定性从两个维度衡量：评估标准差和达标率。

表 6: 五种控制方法全面对比

方法	平均奖励	标准差	达标率	训练步数	是否收敛
随机策略	16.1	6.8	0%	0	否
LQR	44.8	7.4	0%	0	否（模型失配）
规则控制	215.8	29.1	0%	0	否
A2C（优化）	493.4	20.8	90%	200,000	接近收敛
PPO	500.0	0.0	100%	200,000	完全收敛

PPO 的标准差 0 意味着其策略在不同初始条件下 100% 可靠——这是一个控制算法所能达到的最高稳定性水平。A2C 的标准差 20.8 虽然相比优化前（89.8 分时标准差 7.4）已大幅改善，但 90% 的达标率意味着每 10 次控制中有 1 次会意外失败，在要求高可靠性的工业场景中可能不可接受。

规则控制器的标准差 29.1 是五种方法中最高的，但其均值 215.8 分意味着即使“最差情况”（188 分）也远好于 LQR 的“最好情况”（52 分）。这说明启发式规则虽然不够

精确，但具有稳定的基础控制能力。

最终效果排序。综合三个维度（训练速度、稳定性、最终效果），五种方法的总体排名为：

1. **PPO**：完美解决任务，唯一兼具高能力（500 分）和高稳定性（标准差 0）的方法。
2. **A2C**：能力接近 PPO（493.4 分），但稳定性不足（标准差 20.8，达标率 90%）。
3. **规则控制器**：传统方法中最优（215.8 分），无需训练，但远不及 RL 方法。
4. **LQR 控制器**：44.8 分，线性化模型在强非线性系统中基本失效。
5. **随机策略**：16.1 分，性能下界。

Figure 6 | Multi-metric training analysis




图 6：训练过程多指标对比面板。(a) 训练奖励曲线——PPO 平滑收敛至 500，A2C 阶梯状增长；(b) 100 回合移动平均奖励——PPO 单调递增后稳定，A2C 三段式阶梯攀升；(c) 100 回合滚动成功率——PPO 快速跃升至 60% 以上，A2C 后期才出现正值；(d) 回合步数——PPO 在 500 步密集分布，A2C 在 30–160 步间波动。

4 总结体会

4.1 算法效果总结

本实验严格按照任务描述实现了自定义 CartPole 环境（15、-10 失败惩罚），系统对比了五种控制方法。PPO 以满分 500、零标准差完美解决问题，是唯一兼具高能力与高稳定性的算法。优化后的 A2C（`n_steps=64`, `lr=5e-4`）评估均值 493.4、达标率 90%，性能接近 PPO。传统控制方法中，规则控制器（215.8 分）大幅超越 LQR（44.8 分）和随机策略（16.1 分），证明了在强非线性系统中启发式规则的有效性。

4.2 存在的问题与可改进方向

当前实验存在以下不足和改进空间：

- **算法覆盖度不足**：仅对比了 PPO 和 A2C 两种 RL 算法，可引入 SAC（Soft Actor-Critic）、TD3 等更先进的算法进行更全面的对比。
- **A2C 稳定性不足**：优化后的 A2C 仍有 10% 的评估回合失败，可尝试调整网络结构、引入自适应学习率来进一步提升稳定性。
- **超参数搜索不充分**：A2C 的扫描仅覆盖了 `n_steps` 和学习率两个维度，未探索网络深度等架构参数。
- **泛化性验证缺失**：未测试摆杆质量、长度等物理参数变化时的鲁棒性。
- **训练效率**：可引入课程学习或模仿学习来加速训练过程。

4.3 个人收获

通过本次实验，我深入理解了强化学习在自动控制领域中的实际应用。

- 掌握了 PPO 和 A2C 两种主流 RL 算法的核心原理和实现差异——PPO 的裁剪机制如何保证稳定性，A2C 的演员-评论家架构如何降低方差。
- 理解了超参数调优对 RL 算法性能的决定性影响——A2C 从默认参数（后 100 均值 41.2）到优化参数（后 100 均值 464.5）的性能飞跃是这一点的最好证明。
- 认识到传统控制方法与 RL 方法的本质差异：前者依赖精确建模或人工规则，后者通过与环境试错交互自主学习策略。
- 体会到了科学对比的重要性——多维度指标比单一均值能更全面地评估算法性能。

代码仓库：<https://github.com/zhaihuahua78/cartpole-->

报告完成日期：2026 年 7 月