

任务 1 实验报告

基于强化学习的倒立摆控制

课程：AI 赋能自动控制原理 日期：2025 年 7 月

1 问题分析

1.1 Cart Pole 系统与任务环境

Cart Pole（小车-倒立摆）是自动控制原理中经典的非线性系统控制案例。系统由一辆可在轨道上水平移动的小车和铰接于其上的摆杆组成，控制目标是通过施加水平力使摆杆始终保持直立。

本实验采用符合任务描述的自定义 CartPole 环境，参数如下：终止角度 15（摆杆倾斜超过 15 度视为失去平衡），小车边界 2.4m，最大步数 500 步。奖励机制严格遵循任务描述：每步成功保持平衡获得 +1 正向奖励，失败（角度或位置超限）获得-10 负向惩罚。

状态空间为 4 维连续向量（表 1），动作空间为离散二值（0 左移、1 右移）。

表 1: 状态空间

序号	符号	含义	单位
0	x	小车位置	m
1	$\dot{x}$	小车速度	m/s
2	θ	摆杆角度	rad
3	$\dot{\theta}$	摆杆角速度	rad/s

1.2 算法选择

本实验选用以下算法/方法进行对比研究：

PPO(Proximal Policy Optimization): 策略梯度算法, 通过裁剪机制 (clip_range=0.2) 限制策略更新幅度。超参数: 学习率 3×10^{-4} , n_steps 2,048, GAE $\lambda = 0.95$ 。

A2C (Advantage Actor-Critic): 同步优势演员-评论家算法。经超参数扫描 (7 种配置), 最优配置为 n_steps=64、学习率 5×10^{-4} 、熵系数 0.02。该配置下 A2C 后 100 回合均值达 464.5, 评估达标率 90%。

传统控制方法: 随机策略、规则控制器、LQR 控制器, 作为性能基线。

1.3 奖励函数设计

奖励函数严格遵循任务描述：

$$r_t = \begin{cases} +1, & \text{每步成功保持平衡} \\ -10, & \text{失败 } (|\theta| > 15^\circ \text{ 或 } |x| > 2.4 \text{ m}) \end{cases}$$

2 实验过程

2.1 环境构建与参数设置

使用自定义 CartPole 环境（自实现物理引擎）。PPO 和 A2C 各训练 200,000 步。随机种子 42，CPU 设备。

2.2 PPO 训练过程

PPO 在 200,000 步内完美求解（图 1），训练过程分为三个阶段：

- **探索期**（0–200 回合）：奖励 10–40，与随机策略相当，智能体尚未学到有效控制策略；
- **收敛期**（200–280 回合）：奖励从 40 快速攀升至 500，平滑进入求解状态；
- **稳定求解期**（280–737 回合）：持续稳定在满分 500，后 100 回合均值 500.0，无任何退化。

训练总回合 737，累计满分 161 次（21.8%）。20 回合确定性评估全部满分（500.0 ± 0.0），达标率 100%。




图 1： PPO 训练奖励曲线。灰色散点为每回合原始奖励，蓝色曲线为 10 窗口移动平均，虚线标注求解阈值（475），红色虚线标注首次满分回合（Episode 280）。

2.3 A2C 训练过程

A2C 经超参数优化后 ($n_steps=64$, $lr=5e-4$, $ent_coef=0.02$) 在 200,000 步内实现了接近收敛的学习效果 (图 2)。

训练过程可分为：

- **缓慢上升期** (0–200 回合)：均值从 29.3 逐步提升至 226.8，学习速度明显慢于 PPO；
- **波动求解期** (200–500 回合)：出现多次满分尖峰 (第 400 回合首次满分)，但策略不稳定，均值在 300–480 之间波动；
- **稳定提升期** (500–737 回合)：均值逐步提升，后 100 回合均值达 464.5，满分频率明显增加。

训练总回合 737，累计满分 161 次 (21.8%)。20 回合确定性评估均值 493.4 ± 20.8 ，达标率 90% (18/20)。A2C 虽未达到 PPO 的完美稳定度，但已具备强大的求解能力，与 PPO 的差距较小。




图 2: A2C 训练奖励曲线。绿色散点为原始奖励，曲线为 50 窗口移动平均。A2C 在训练后期接近收敛，后 100 回合均值 464.5。

2.4 传统控制方法对比

传统控制方法作为性能基线，从设计原理、实现方式和实验结果三个维度进行评估：

随机策略：每步以 50% 概率随机选择左移或右移，无任何反馈机制。作为性能下界，用于衡量任务固有难度。20 回合评估平均仅 16.1 步，标准差 6.8。

LQR 控制器：在平衡点 ($\theta = 0$) 附近对 CartPole 非线性动力学方程进行线性化，得到状态空间模型 $\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}u$ 。通过求解代数 Riccati 方程 $\mathbf{A}^T \mathbf{P} + \mathbf{P}\mathbf{A} - \mathbf{P}\mathbf{B}\mathbf{R}^{-1}\mathbf{B}^T \mathbf{P} + \mathbf{Q} = 0$ 获得最优反馈增益矩阵 $\mathbf{K}$ ，控制律为 $u = -\mathbf{K}\mathbf{x}$ 。权重矩阵设为 $\mathbf{Q} = \text{diag}(10, 1, 100, 1)$, $\mathbf{R} = 1$ ，重点惩罚角度偏差。20 回合评估均值 44.8 步。LQR 在

CartPole 上表现不佳的根本原因在于：该系统是强非线性的（摆杆角度可在 $\pm 15^\circ$ 范围内变化），而 LQR 仅在平衡点邻域内线性化，在大角度偏差时线性近似误差极大，导致控制力方向判断失误。

规则控制器：基于领域知识的启发式控制策略，控制规则为：

- 若摆杆向右倾斜 ($\theta > 0.05 \text{ rad}$) $\rightarrow$ 向右推
- 若摆杆向左倾斜 ($\theta < -0.05 \text{ rad}$) $\rightarrow$ 向左推
- 若角度较小，则根据角速度方向施加推力

该控制器无需建模，直接利用物理直觉设计。20 回合评估均值 215.8 步，远优于 LQR 和随机策略，证明在强非线性系统中，启发式规则可能超越基于线性化模型的最优控制。

表 2: 传统控制方法性能对比（20 回合评估）

方法	平均奖励	标准差	最高奖励	设计复杂度
随机策略	16.1	6.8	43	无
LQR 控制器	44.8	7.4	52	高（需建模 + 求解 Riccati）
规则控制器	215.8	29.1	293	低（启发式规则）

3 实验结果及分析

3.1 PPO 训练过程多指标分析

本节从奖励曲线、滚动平均奖励、滚动成功率和回合步数四个维度，对 PPO 训练过程进行深度分析（图 5a-d 蓝色曲线）。

奖励曲线分析：PPO 的奖励曲线呈典型的 S 形增长。三个阶段特征清晰：探索期（0-200 回合）奖励集中在 10-40 的低水平区间，呈均匀随机分布；收敛期（200-280 回合）奖励从 40 陡峭攀升至 500，斜率最大，是策略质变的关键窗口；求解期（280 回合后）奖励密集分布在 500 满分附近，少量回落回合出现在 280-350 回合之间，350 回合后几乎无回落。

滚动平均奖励 (w=100)：滚动均值从约 50（100 回合处）匀速增长至 500（300 回合处），之后严格稳定在 500 不变。这一单调递增且最终稳定的曲线形态，是算法收敛性理想的标志。

滚动成功率 (w=100, 阈值 475)：成功率曲线从 0%（100 回合处）开始，在 200-300 回合之间快速跃升至 60% 以上，300 回合后稳定在 60%-100% 之间。值得注意的是，成功率并非 100%——即使在后期的满分区域，仍有约 20%-40% 的回合因初始状态扰动而未能达到满分。这说明 PPO 的策略已接近最优，但 CartPole 环境的随机初始状态给完全稳定控制带来了挑战。

回合步数：回合步数与奖励完全正相关（每步 +1，失败 -10）。求解期的步数密集分布在 500 步附近，少量因失败提前终止的回合步数在 50-200 之间。回合步数的方差在

后期显著减小，反映了策略鲁棒性的提升。

3.2 A2C 训练过程多指标分析

奖励曲线分析：A2C 的奖励曲线呈现与 PPO 不同的多尖峰模式。在 0–200 回合阶段，奖励散点分布均匀（10–40），与随机策略无明显差异。200 回合后开始出现零星高分（100–300），但回落频繁——这可能与 A2C 不使用裁剪机制有关，单次策略更新幅度过大导致性能波动。400 回合后满分尖峰频率增加，后 100 回合均值达到 464.5，说明策略正在接近收敛。

滚动平均奖励 ($w=100$): A2C 的滚动均值从约 30（100 回合处）缓慢增长至约 480（700 回合处），增长曲线呈阶梯状而非 PPO 的平滑递增，反映了 A2C“突进-回落-再突进”的学习模式。500 回合后滚动均值的波动幅度减小，表明策略趋于稳定。

滚动成功率：成功率曲线与 PPO 形成鲜明对比。PPO 的成功率快速升至 60% 后保持稳定；A2C 的成功率在大部分训练时间内接近 0%，仅在后 200 回合才开始出现正值，最终不超过 30%。这一指标说明 A2C 在求解可靠性上仍与 PPO 有显著差距。

回合步数：A2C 的回合步数在训练的大部分时间内集中在 30–160 之间，对应奖励 30–150。后 200 回合开始出现 500 步的满分回合，但频率不高且不连续。

3.3 控制方法综合对比




图 3：五种控制方法平均奖励对比（20 回合评估，误差棒表示标准差）。PPO 满分 500，A2C 493.4 分，规则控制器 215.8 分，LQR 44.8 分，随机策略 16.1 分。红色虚线标注求解阈值（475）。

表 3: 五种控制方法全面对比

方法	平均奖励	标准差	达标率	训练速度	稳定性
随机策略	16.1	6.8	0%	—	—
LQR	44.8	7.4	0%	无需训练	稳定但差
规则控制	215.8	29.1	0%	无需训练	稳定
A2C	493.4	20.8	90%	200k 步/3min	较稳定
PPO	500.0	0.0	100%	200k 步/2min	极稳定

训练速度（收敛效率）：PPO 在约 280 回合（约 35,000 步环境交互）时首次达到满分，A2C 在约 400 回合（约 25,000 步）时首次满分。但 PPO 首次满分后能持续保持，而 A2C 需要更长时间才能稳定。从时间角度，两者均可在 2–3 分钟内完成 200k 步训练，效率接近。

稳定性：PPO 的评估标准差为 0（20 回合全满分），表现出完美的策略稳定性。A2C 的标准差为 20.8，虽然 90% 的回合达标，但仍有 10% 的回合因初始状态扰动而失败，策略鲁棒性略逊于 PPO。规则控制器的标准差较大（29.1），反映其在不同初始条件下表现差异大。LQR 和随机策略的标准差较小但均值极低——低方差在此情况下并非优势。

最终效果：PPO 以 500 满分、100% 达标率位居第一；A2C 以 493.4 分、90% 达标率紧随其后；规则控制器以 215.8 分位居第三，虽远不及 RL 方法，但证明了简单启发式规则在 CartPole 问题上的有效性。LQR（44.8 分）和随机策略（16.1 分）不具备实际控制能力。




图 4: 训练前后 20 回合评估奖励分布。PPO（蓝色）箱体压缩为单值 500（零方差）；A2C（绿色）中位数约 500 但有 3 个异常值；随机策略（灰色）均值 16 分。散点为各回合个体数据。

Figure 6 | Multi-metric training analysis




图 5: 训练过程多指标对比面板。(a) 训练奖励曲线; (b) 100 回合移动平均奖励; (c) 100 回合滚动成功率 (阈值 475); (d) 回合步数。

4 总结体会

本实验严格按任务描述实现了自定义 CartPole 环境 (15、-10 失败惩罚)，系统对比了五种控制方法。

核心结论：

1. PPO 以 500 满分、100% 达标率完美解决问题，是五种方法中的最优选择；
2. 优化后的 A2C ($n_steps=64$, $lr=5e-4$) 评估均值 493.4、达标率 90%，性能接近 PPO 但稳定性略逊；
3. 规则控制器 (215.8 分) 证明简单的领域知识可大幅超越线性化最优控制 (LQR, 44.8 分)；
4. 多指标分析 (奖励曲线、滚动均值、成功率、回合步数) 提供了比单一均值更全面的评估视角。

改进方向：可尝试 SAC 等更先进算法；进一步优化 A2C 网络结构；引入课程学习加速收敛。

代码仓库: <https://github.com/zhaihuahua78/cartpole-->

报告完成日期: 2025 年 7 月